



UNIVERZITET U NIŠU
ELEKTRONSKI FAKULTET

Katedra za računarstvo



DETEKCIJA LAŽNIH OGLASA ZA POSAO

SEMINARSKI RAD

Predmet: Prikupljanje i predobrada podataka za mašinsko učenje

Student:

Nemanja Stojanović 2126

Mentor:

dr Aleksandar Stanimirović

Sadržaj

1. Uvod	2
2. Detekcija lažnih oglasa za posao kao problem klasifikacije	3
3. Kvalitet tekstualnih podataka	4
3.1 Dužina dokumenata.....	5
3.2 Veličina rečnika	5
3.3 Leksička raznovrsnost.....	5
3.4 Šum u tekstualnim podacima	6
4. Predobrada tekstualnih podataka	7
4.1 Tokenizacija	7
4.2 Normalizacija	8
4.3 Uklanjanje stop-reči	8
4.4 Stemming i lematizacija.....	8
4.5 Data augmentation.....	9
5. Reprezentacija teksta za mašinsko učenje	9
5.1 Bag of Words	9
5.2 TF-IDF	10
5.3 Word embeddings i subword ideja.....	10
5.4 Transformer arhitektura i DistilBERT	11
6. Metodologija procene uticaja predobrade	11
7. Praktična demonstracija na skupu oglasa	12
8. Eksperimentalna postavka i baseline.....	14
9. Rezultati i diskusija.....	15
9.1 Bag of Words i TF-IDF	16
9.2 Word2Vec i FastText rezultati	16
9.3 DistilBERT kao feature extractor	17
9.4 Robusnost na kontrolisani šum.....	17
9.5 Analiza grešaka i interpretabilnost.....	18

10. Uslovi primene, prednosti i ograničenja.....	18
10.1 Kvalitet oznaka i definicija ciljne klase	19
10.2 Dužina dokumenta i problem skraćivanja.....	19
10.3 Izbor tokenizacije kao kompromis.....	20
10.4 Normalizacija i rizik gubitka informacije.....	20
10.5 Data augmentation i semantička validnost.....	21
10.6 Evaluacija, izbor modela i statistička nesigurnost.....	21
10.7 Promena domena i praćenje modela.....	21
10.8 Operativna i etička primena.....	22
11. Zaključak	22
12. Literatura	23

1. Uvod

Mašinsko učenje danas ima značajnu primenu u obradi tekstualnih podataka. Veliki broj praktičnih problema svodi se na automatsko razumevanje, organizaciju i klasifikaciju tekstualnog sadržaja. Takvi problemi obuhvataju filtriranje neželjene pošte, analizu sentimenta, prepoznavanje tema, pretragu dokumenata, detekciju govora mržnje, klasifikaciju vesti, kao i prepoznavanje prevara i obmanjujućih tekstova.

Iako savremeni modeli mogu da postignu veoma dobre rezultate, njihov uspeh ne zavisi samo od izbora algoritma. Jedan od ključnih faktora je kvalitet podataka nad kojima se model trenira.

Kod strukturiranih podataka kvalitet se najčešće razmatra kroz nedostajuće vrednosti, pogrešne tipove podataka, nekonzistentne formate ili ekstremne vrednosti. Kod tekstualnih podataka situacija je složenija. Tekst ima nestrukturisanu prirodu, sadrži sinonime, pravopisne greške, specijalne znakove, pa čak i fragmente HTML-a ili automatski generisanog sadržaja.

Tema ovog rada odnosi se na kvalitet i predobradu tekstualnih podataka u kontekstu detekcije lažnih oglasa za posao. Ovaj problem je praktično veoma značajan, jer lažni oglasi mogu dovesti do raznih posledica, krađe ličnih podataka, gubitka vremena i gubitka poverenja u digitalne platforme za zapošljavanje.

Sa stanovišta mašinskog učenja, ovde je reč o zadatku binarne klasifikacije u kome treba odrediti da li je dati oglas legitiman ili lažni.

Cilj rada je dvostruk. Prvi cilj je teorijska analiza kvaliteta tekstualnih podataka i najčešćih tehnika predobrade koje se koriste u klasifikaciji teksta. Drugi cilj je povezivanje tih pojmova sa konkretnim praktičnim primerom u kome se porede različite varijante pripreme teksta i njihovo dejstvo na performanse modela za klasifikaciju oglasa za posao.

Rad je organizovan tako da se najpre obrađuje teorijska osnova, zatim se definiše metodologija baseline eksperimenta i uslovi fer poređenja. Tek u završnom delu teorijske tehnike se demonstriraju na izabranom skupu podataka, porede se početni i unapređeni rezultati i iznose preporuke za primenu.

2. Detekcija lažnih oglasa za posao kao problem klasifikacije

Internet platforme za zapošljavanje poput "LinkedIn" omogućile su značajno brže povezivanje kompanija i kandidata. Međutim, velika dostupnost i lako objavljivanje oglasa stvorili su prostor i za zloupotrebe.

U poslednjih nekoliko godina stalno možemo videti jedne te iste oglase na kojima je prijavljeno preko 100 kandidata, a niko nije dobio odgovor.

Ovakvi oglasi za posao mogu imati više ciljeva. Nekada se koriste za prikupljanje ličnih podataka kandidata, kao što su email adresa, broj telefona ili skenirana dokumentacija. Nekada je cilj direktna finansijska prevara, na primer traženje uplate za obuku, opremu ili navodni trošak obrade prijave. U drugim slučajevima lažni oglasi služe za širenje spama, služe za promociju kompanije ili prikupljanje baze kontakata.

Sa tehničke strane, detekcija lažnih oglasa predstavlja problem binarne klasifikacije. Za svaki oglas potrebno je proceniti da li pripada klasi real ili klasi fake. Na prvi pogled može delovati da je ovaj zadatak jednostavan, jer se lažni oglasi ponekad prepoznaju po izrazima koji zvuče sumnjivo, kao što su obećanja brže zarade, nejasni uslovi rada ili odsustvo konkretnih informacija o kompaniji. Ipak, u praksi veliki broj lažnih oglasa pokušava da imitira ton i strukturu legitimnih oglasa. Upravo zbog toga automatska klasifikacija nije trivijalna.

Jedan od glavnih izazova jeste to što se tekstualne osobine legitimnih i lažnih oglasa delom preklapaju. Oglasi za posao, bez obzira na autentičnost, često koriste slične obrasce: opis odgovornosti, spisak zahteva, informacije o benefitima i kratku prezentaciju kompanije. Ako model nauči samo površne razlike, postoji opasnost da dobro radi na jednom skupu podataka, ali loše generalizuje na novim primerima. Zbog toga je kvalitet skupa podataka od presudnog značaja.

Drugi izazov je prisustvo shortcut signala. To su osobine koje model može vrlo lako da iskoristi za predikciju, ali koje zapravo ne odražavaju suštinski problem. Na primer, ako svi lažni oglasi u skupu nemaju veb sajt, a svi legitimni imaju, model će brzo naučiti da koristi taj signal i postići visoku tačnost bez stvarnog razumevanja teksta oglasa. Takvi rezultati mogu izgledati impresivno, ali nisu pouzdani u realnim uslovima.

Upravo zato se u analizi detekcije lažnih oglasa ne sme posmatrati samo izbor modela. Podjednako je važno pitanje kako su podaci pripremljeni, koliko su tekstovi realni, koliko se dve klase preklapaju i da li predobrada doprinosi stabilnijem i smislenijem učenju.

3. Kvalitet tekstualnih podataka

Kvalitet tekstualnih podataka može se posmatrati kroz više dimenzija. Za razliku od tabelarnih podataka, gde su greške često direktno vidljive, kod teksta i manje nepravilnosti mogu značajno uticati na reprezentaciju dokumenta. U ovom radu posebno su važni dužina dokumenata, veličina rečnika, leksička raznovrsnost i prisustvo šuma.

Analiza kvaliteta organizovana je oko sledećih grupa pokazatelja:

- dužina dokumenta u karakterima, rečima i rečenicama;
- veličina rečnika i broj retkih tokena;
- leksička raznovrsnost i prosečna dužina reči;
- HTML, URL, email i emoji sadržaj;

- kapitalizacija, interpunkcija i brojčani obrasci;
- typo, spam i OCR-like indikatori.

3.1 Dužina dokumenata

Dužina dokumenta predstavlja jednu od osnovnih osobina tekstualnog skupa. Kratki dokumenti često sadrže premalo informacija da bi model mogao da izdvoji stabilne obrasce. Ako oglas ima samo jednu ili dve rečenice, klasifikacija se svodi na mali broj tokena i model lako postaje osetljiv na pojedinačne reči. Sa druge strane, veoma dugi dokumenti mogu sadržati korisne informacije, ali i mnogo redundanse, opisa i opšteg teksta koji ne doprinosi direktno odluci.

Kod oglasa za posao dužina teksta može imati indirektan značaj. Veoma kratki oglasi ponekad deluju neprofesionalno i mogu biti sumnjivi. Ipak, ni dugi i detaljni oglasi nisu automatski legitimni. Neki lažni oglasi namerno koriste dugačak i formalno napisan tekst kako bi izgledali ubedljivije. Zbog toga dužina teksta treba da se posmatra kao pomoćna metrika, a ne kao jedini signal.

U praktičnom delu projekta dužina teksta je jedna od analiziranih osobina. Ona omogućava pregled raspodele dokumenta i poređenje klasa. Takva analiza je korisna jer pomaže da se stekne utisak o homogenosti skupa i eventualnim ekstremnim primerima.

3.2 Veličina rečnika

Veličina rečnika, odnosno vocabulary size, predstavlja broj jedinstvenih reči ili tokena koji se pojavljuju u skupu podataka. Ova mera je važna zato što pokazuje koliko je jezik u skupu raznovrstan, ali i koliko potencijalnog šuma postoji. Ako je rečnik prevelik u odnosu na broj dokumenata, moguće je da skup sadrži mnogo retkih reči, grešaka u kucanju, varijacija iste reči ili sporednih tokena.

Kod klasičnih reprezentacija kao što su Bag of Words i TF-IDF, velika veličina rečnika dovodi do veoma retkih matrica osobina, u kojima je većina vrednosti jednaka nuli.

To može povećati računarsku složenost i otežati učenje modela, posebno kada veliki broj tokena nosi malo informacije. Na primer, dve reči koje se razlikuju samo po velikom i malom slovu ili po prisustvu interpunkcije mogu biti tretirane kao različite, iako semantički nose isto značenje.

Predobrada teksta često smanjuje veličinu rečnika. Lowercasing spaja reči koje se razlikuju samo po registru slova, uklanjanje interpunkcije uklanja tehničke varijacije, dok stemming i lematizacija objedinjavanjem oblika reči dodatno smanjuju broj jedinstvenih tokena. Time se modelu olakšava da prepozna opšte obrasce umesto da troši kapacitet na površne razlike.

3.3 Leksička raznovrsnost

Leksička raznovrsnost, odnosno lexical diversity, opisuje odnos između broja jedinstvenih reči i ukupnog broja reči u dokumentu. Intuitivno, ona govori koliko je rečnik nekog dokumenta

raznovrstan. Tekst koji više puta ponavlja iste izraze imaće manju leksičku raznovrsnost od teksta koji koristi šire i bogatije vokabularne obrasce.

Ova mera je korisna pri analizi kvaliteta skupa podataka. Niska leksička raznovrsnost može ukazivati na šablonske, automatski generisane ili spam tekstove. Visoka raznovrsnost ne mora automatski značiti visok kvalitet, ali može ukazivati na prirodniji i sadržajni tekst. U domenu oglasa za posao, leksička raznovrsnost može pomoći da se identifikuje da li klasa sadrži mnogo ponovljenih obrazaca ili se opisi značajno razlikuju međusobno.

Naravno, ova metrika ima ograničenja. Na nju utiče i sama dužina teksta. Kraći dokumenti mogu imati naizgled visoku raznovrsnost samo zato što imaju malo reči, dok duži dokumenti mogu imati nešto nižu vrednost zbog prirodnog ponavljanja termina iz domena. Zbog toga leksičnu raznovrsnost treba tumačiti zajedno sa drugim pokazateljima, a ne izolovano.

3.4 Šum u tekstualnim podacima

Jedan od najvažnijih problema kod tekstualnih podataka jeste prisustvo šuma. Pod šumom se podrazumevaju elementi teksta koji otežavaju reprezentaciju, uvode nepotrebne varijacije ili smanjuju informativnost tokena. Šum može imati više oblika.

U ovoj analizi razlikuju se:

- tipografske i pravopisne greške;
- HTML fragmenti i tehničke oznake;
- URL i email obrasci;
- emoji i nestandardni Unicode simboli;
- spam fraze i ponovljena interpunkcija;
- OCR-like zamene, kao što su 0/O i 1/I;
- nekonzistentna kapitalizacija i formati.

Prvi oblik su tipografske i pravopisne greške. One mogu nastati slučajno, usled brzog kucanja, nepoznavanja jezika ili automatski generisanog sadržaja. Za model koji koristi reči kao osnovne jedinice, svaka takva greška stvara novi token. Reč client i oblik cllent formalno postaju različiti, iako imaju isto značenje.

Drugi oblik šuma su HTML fragmenti, specijalni znakovi i tehničke oznake. Tekst preuzet sa veba često sadrži oznake za formatiranje, nepotrebne simbole, delove URL adresa ili neujednačene razmake. Takav sadržaj retko nosi korisnu semantiku za klasifikaciju, ali može značajno povećati broj tokena.

Treća grupa šuma obuhvata spam obrasce i neinformativne fraze. U mnogim tekstualnim zadacima, određeni delovi teksta su formalno ispravni, ali ne doprinose stvarnom razumevanju dokumenta. Kod oglasa za posao to mogu biti opšte fraze koje se pojavljuju skoro svuda, kao što su dynamic environment, great opportunity ili communication skills, ukoliko nisu dopunjene konkretnim informacijama.

Četvrta grupa su nekonzistentni formati. Isti pojam može biti zapisan na više načina, na primer remote, Remote, REMOTE ili remote-work. Bez odgovarajuće normalizacije model takve oblike posmatra kao različite tokene. To povećava rasutost osobina i može umanjiti kvalitet učenja.

U kontekstu ovog rada šum je posebno zanimljiv, jer je u praktičnom delu namerno prisutan u određenoj meri kako bi eksperiment bio realniji. Time se ispituje u kojoj meri osnovne tehnike predobrade mogu da dovedu do urednije i informativnije reprezentacije teksta.

4. Predobrada tekstualnih podataka

Predobrada predstavlja skup postupaka kojima se sirovi tekst priprema za dalju analizu i modelovanje. Cilj predobrade nije samo da se tekst učini "čistijim", već i da se dobije reprezentacija koja bolje odražava važne obrasce u podacima. Izbor koraka predobrade zavisi od zadatka, jezika, veličine skupa i vrste modela koji se koristi.

Praktični tok predobrade obuhvata:

1. uklanjanje HTML oznaka, URL-ova, email adresa i emoji simbola;
2. NFKC Unicode normalizaciju i case folding;
3. uklanjanje brojeva, interpunkcije i višestrukih razmaka;
4. formiranje verzije bez stop-reči;
5. Porter stemming i WordNet lematizaciju kao odvojene varijante;
6. kontrolisani data augmentation samo nad trening skupom.

4.1 Tokenizacija

Tokenizacija je postupak razlaganja teksta na manje jedinice, najčešće reči, rečenice ili podrečne segmente. To je osnovni korak u gotovo svim NLP postupcima, jer većina modela ne radi direktno nad sirovim nizom karaktera.

Word tokenization deli tekst na reči. Ovaj pristup je intuitivan i posebno koristan kod klasičnih reprezentacija kao što su Bag of Words i TF-IDF. Njegova prednost je jednostavnost, ali i određena ograničenja. Na primer, složeni izrazi, skraćenice i reči sa specijalnim znacima nisu uvek lako obradive.

Sentence tokenization deli tekst na rečenice. Ona je korisna kada je potrebno analizirati strukturu dokumenta, pratiti lokalni kontekst ili vraćati se na pojedinačne iskaze unutar dužeg teksta. U detekciji lažnih oglasa rečenice mogu biti zanimljive zato što oglas često ima prepoznatljivu organizaciju: uvod, odgovornosti, zahtevi i benefiti.

Subword tokenization je posebno važna kod savremenih neuralnih modela i transformer arhitektura. Umesto da reči tretira kao nedeljive jedinice, ona ih razlaže na manje delove. Time modeli bolje podnose retke reči, morfološke varijacije i nepoznate oblike. U ovom projektu

subword ideja praktično se prikazuje kroz character n-gram TF-IDF, FastText i tokenizer prethodno obučenog modela DistilBERT.

4.2 Normalizacija

Normalizacija podrazumeva transformisanje teksta u ujednačen format. To je jedan od najčešće korišćenih i najprirodnijih koraka predobrade. Najjednostavniji oblik normalizacije jeste pretvaranje svih slova u mala slova. Time se reči Team, team i TEAM tretiraju kao isti token.

Pored lowercasing-a, često se uklanjaju interpunkcija i brojevi. Interpunkcija u nekim zadacima može biti korisna, na primer u analizi sentimenta ili stilistike, ali kod klasične klasifikacije dokumenata često samo uvodi dodatne varijacije bez značajne koristi. Uklanjanje brojeva zavisi od domena. U nekim slučajevima brojevi nose važnu informaciju, ali u mnogim tekstualnim skupovima uglavnom predstavljaju šum.

Normalizacija može obuhvatiti i Unicode standardizaciju, uklanjanje višestrukih razmaka, obradu specijalnih karaktera i standardizaciju skraćenica. U praktičnom delu ovog projekta koristi se osnovna normalizacija koja uključuje lowercasing, uklanjanje interpunkcije, uklanjanje brojeva i sređivanje razmaka. Ovaj korak je važan zato što smanjuje veličinu rečnika i spaja površinske varijacije tokena.

4.3 Uklanjanje stop-reči

Stop-reči su veoma česte reči koje se pojavljuju u velikom broju dokumenata i često nose malo diskriminativne informacije. U engleskom jeziku to su, na primer, reči kao što su the, and, is, in, on, for. U mnogim zadacima njihovo uklanjanje pojednostavljuje reprezentaciju teksta i omogućava modelu da se više usmeri na sadržajne termine.

Ipak, uklanjanje stop-reči nije univerzalno dobro rešenje. U nekim kontekstima funkcijske reči mogu nositi važne informacije o stilu, tonu ili gramatici. Kod određenih zadataka, kao što su analiza sentimenta ili stilometrija, i reči koje se često ponavljaju mogu biti korisne. Zbog toga odluku o uklanjanju stop-reči treba donositi u odnosu na konkretan problem.

Kod detekcije lažnih oglasa uklanjanje stop-reči može pomoći da se istaknu termini povezani sa zaposlenjem, odgovornostima, zahtevima, benefitima, kontaktom i potencijalno sumnjivim obrascima. U praktičnom delu projekta jedna od varijanti teksta upravo je verzija bez stop-reči, kako bi se procenilo da li takvo pojednostavljenje poboljšava metrike klasifikacije.

4.4 Stemming i lematizacija

Stemming i lematizacija imaju sličan cilj: svođenje različitih oblika reči na zajedničku osnovu. Međutim, oni to rade na različite načine.

Stemming je jednostavniji i grublji postupak. On mehanički skraćuje reč na osnovu pravila, ne vodeći računa uvek o tome da li rezultat predstavlja stvarnu reč. Na primer, reči connected,

connecting i connection mogu biti svedene na zajedničku osnovu connect ili neku njenu aproksimaciju. Prednost stemminga je jednostavnost i brzina, dok je mana to što ponekad proizvodi neprirodne oblike.

Lematizacija je lingvistički preciznija. Ona nastoji da svaku reč vrati na njen leksički osnovni oblik, takozvanu lemu. Za to su najčešće potrebni rečnici i gramatička pravila. Rezultat je interpretabilniji, ali je postupak složeniji i zahteva više jezičkih resursa.

U ovom projektu koriste se i stemming i lematizacija. Stemming je implementiran pomoću PorterStemmer algoritma, dok se za lematizaciju koristi WordNetLemmatizer iz NLTK biblioteke. WordNet pristup daje stvarne leksikografske oblike, ali se u ovoj implementaciji ne koristi POS tagger, pa rezultat nije uvek lingvistički optimalan. Poređenje ipak jasno pokazuje razliku između agresivnog mehaničkog skraćivanja i rečnički zasnovanog svođenja reči na lemu.

4.5 Data augmentation

Data augmentation u obradi teksta podrazumeva generisanje novih varijanti postojećih primera kako bi model imao više raznovrsnih podataka za treniranje. Za razliku od slika, gde su transformacije kao što su rotacija ili skaliranje relativno prirodne, kod teksta je potrebno paziti da se pri transformaciji ne izgubi originalno značenje.

Jedan od pristupa je zamena reči sinonimima. Drugi pristup je nasumično uklanjanje ili ubacivanje manje važnih reči. Koriste se i metode kao što su back translation, gde se tekst prevede na drugi jezik pa vrati nazad, kao i generativni modeli za parafraziranje. Prednost augmentation-a je povećanje varijabilnosti skupa, ali je rizik u tome što automatizovane izmene mogu uneti semantičku grešku ili veštačke obrasce.

U praktičnom delu implementirana je jednostavna forma augmentation-a nad trening skupom. Ona koristi malu ručno definisanu mapu sinonima i povremeno izbacivanje pojedinih tokena. Ova varijanta nije zamena za napredne tehnike parafraziranja, ali dobro demonstrira osnovnu ideju: model se trenira i na blago izmenjenim primerima kako bi se proverilo da li dodatna raznovrsnost poboljšava generalizaciju.

5. Reprezentacija teksta za mašinsko učenje

Mašinski modeli ne mogu direktno da rade nad sirovim tekstom. Zbog toga je potrebno tekst pretvoriti u numerički oblik. Način na koji se to radi veoma utiče na kvalitet kasnijeg modela. U ovoj oblasti razlikuju se klasični pristupi zasnovani na frekvenciji tokena i savremeniji pristupi koji koriste gustu vektorsku reprezentaciju i kontekstualno učenje.

5.1 Bag of Words

Bag of Words je jedan od najstarijih i najjednostavnijih modela reprezentacije teksta. Ideja je da se dokument predstavi kao multiskup reči, pri čemu se ne uzima u obzir redosled reči, već samo njihovo prisustvo ili frekvencija.

Prednost ovog pristupa je jednostavnost i interpretabilnost. Lako je objasniti šta koja osobina predstavlja i brzo ga je moguće primeniti na veliki broj dokumenata. Zbog toga je Bag of Words i dalje važna polazna tačka u mnogim praktičnim problemima.

Glavna mana je gubitak redosleda i konteksta. Reči koje imaju različito značenje u različitim okruženjima tretiraju se isto. Pored toga, dobija se reprezentacija sa velikim brojem dimenzija u kojoj je većina vrednosti jednaka nuli.

Uprkos tim manama, Bag of Words i dalje može dati dobre rezultate u problemima klasifikacije dokumenata, posebno kada je kombinovan sa odgovarajućom predobradom.

5.2 TF-IDF

TF-IDF, odnosno Term Frequency - Inverse Document Frequency, predstavlja unapređenje klasičnog brojanja reči. Ideja je da se visoka težina dodeli terminima koji su česti u datom dokumentu, ali ne i preterano česti u svim dokumentima. Na taj način se umanjuje značaj reči koje se pojavljuju gotovo svuda i ističu termini koji bolje razlikuju dokumente.

TF-IDF je posebno pogodan za zadatke klasifikacije tekstova. On zadržava interpretabilnost klasičnih reprezentacija zasnovanih na učestalosti reči, ali važnijim i karakterističnijim rečima dodeljuje veće težine. Zbog toga se često koristi kao snažan referentni pristup u praktičnim NLP projektima.

U ovom projektu TF-IDF predstavlja osnovnu tekstualnu reprezentaciju. To je smislen izbor, jer omogućava da se efekti predobrade lako uoče. Kada se promeni tekstualni oblik reči, ta promena se direktno odražava na rečnik i težine u TF-IDF matrici. Zbog toga je ovaj pristup pogodan za analizu uticaja normalizacije, stop-reči i stemminga.

5.3 Word embeddings i subword ideja

Word embeddings predstavljaju reči gustim vektorima u kojima geometrijska bliskost odražava sličnost konteksta. Za razliku od Bag of Words i TF-IDF reprezentacija, gde svaka reč dobija nezavisnu dimenziju, embedding prostor omogućava da povezani izrazi imaju slične numeričke prikaze.

Word2Vec se zasniva na distribucionoj pretpostavci da se značenje reči može učiti iz njenog konteksta. U CBOW varijanti okolne reči koriste se za predviđanje centralne reči, dok skip-gram radi obrnuto. Prednosti Word2Vec pristupa su kompaktna reprezentacija i mogućnost učenja

semantičkih odnosa. Ograničenje je to što svaka reč ima jedan statički vektor bez obzira na kontekst, a reči van rečnika nemaju prirodnu reprezentaciju.

FastText proširuje ideju statičkih embeddinga karakterskim n-gramima. Vektor reči nastaje kombinovanjem informacije o celoj reči i njenim podrečnim segmentima. Ovaj pristup je pogodan za tekst sa morfološkim varijacijama, retkim rečima i tipografskim greškama, jer i nepoznata reč može deliti deo n-grama sa poznatim rečima.

U praktičnom delu ovog rada Word2Vec i FastText se koriste preko biblioteke gensim. Dokument se predstavlja prosekom naučenih vektora svojih tokena, a nad tom reprezentacijom trenira se LogisticRegression klasifikator. Pored toga, subword ideja se ispituje i kroz character n-gram TF-IDF. Time se pokrivaju oba pristupa: klasični word embedding modeli i jednostavnija karakterska reprezentacija koja je laka za interpretaciju.

5.4 Transformer arhitektura i DistilBERT

Transformer modeli koriste mehanizam self-attention kako bi reprezentaciju svakog tokena prilagodili drugim tokenima u sekvenci. Za razliku od statičkih embeddinga, ista reč dobija različitu reprezentaciju u zavisnosti od konteksta. BERT dodatno koristi bidirekciono pretrreniranje, pa se jezik uči na velikom korpusu pre prilagođavanja konkretnom zadatku.

DistilBERT predstavlja kompaktniju verziju BERT modela dobijenu destilacijom znanja. Ima manje slojeva i brže izvršavanje, uz zadržavanje velikog dela jezičkog znanja originalnog modela. U praktičnom delu rada DistilBERT se koristi kao feature extractor, a ne kao potpuno fine-tuned klasifikator. To znači da pretrained model pretvara tekst u guste vektorske reprezentacije, dok se nad tim vektorima trenira jednostavan Logistic Regression klasifikator.

Ovakav pristup predstavlja kompromis između klasičnog TF-IDF modela i punog fine-tuning-a Transformera. Sa jedne strane, koristi se jezičko znanje naučeno na velikom korpusu. Sa druge strane, izbegava se složen trening velikog broja parametara, podešavanje epoha i izbor praga na validation skupu. Ova postavka omogućava jasno poređenje pretrained reprezentacija sa klasičnim modelima, uz jednostavnije objašnjenje i reprodukciju eksperimenta.

6. Metodologija procene uticaja predobrade

Predobrada nije korisna sama po sebi, već samo ako poboljšava podatke u odnosu na jasno definisan cilj. Smanjenje veličine rečnika ili uklanjanje HTML-a može izgledati poželjno, ali ne dokazuje da je model postao precizniji, stabilniji ili robusniji. Efekat svake tehnike zato treba proveriti kontrolisanim eksperimentom.

Prvi korak je uspostavljanje baseline-a. U klasifikaciji teksta baseline treba da bude jednostavan, reproduktivan i dovoljno smislen da predstavlja realnu početnu tačku. Primer je Bag of Words

reprezentacija sirovog teksta sa logističkom regresijom. Takav model pokazuje šta se može postići bez složenije normalizacije, težinskih šema, semantičkih vektora ili pretrained modela.

Nakon baseline-a menja se jedna grupa odluka: način predobrade, reprezentacija ili model. Train/test podela i primarna metrika ostaju iste. Ako se istovremeno promene tekst, vektorizator, klasifikator i podela podataka, nije moguće zaključiti koja promena je odgovorna za razliku u rezultatu.

Vektorizator, rečnik, IDF težine, embedding modeli, skaleri i parametri imputacije moraju se učiti samo na trening podacima. Učenje rečnika na celom skupu prenosi informacije o test dokumentima i predstavlja curenje podataka, čak i kada ciljne oznake nisu direktno korišćene. Augmentacija se takođe sme primeniti samo na trening deo.

Za binarnu klasifikaciju koriste se accuracy, precision, recall i F1. U antifraud zadatku recall pozitivne klase meri koliko je lažnih oglasa otkriveno, dok precision pokazuje koliko je označenih oglasa zaista lažno. F1 predstavlja kompromis ove dve mere. Izbor primarne metrike i praga treba da odražava trošak false positive i false negative grešaka.

Jedna holdout podela omogućava jednostavno poređenje i analizu grešaka, ali ne meri varijabilnost rezultata. Zato glavne konfiguracije treba proveriti stratifikovanom unakrsnom validacijom. Srednja vrednost opisuje očekivani rezultat, a standardna devijacija upozorava kada je razlika između dve metode manja od nestabilnosti izazvane podelom podataka.

Kvalitet tehnike treba oceniti kroz više kriterijuma:

- promenu modelske metrike u odnosu na baseline;
- stabilnost kroz foldove ili ponovljene podele;
- promenu veličine rečnika i dužine dokumenata;
- otpornost na kontrolisani i prirodni šum;
- računarsku cenu i vreme izvršavanja;
- interpretabilnost i mogućnost analize grešaka;
- ponašanje na drugom izvoru ili vremenskom periodu.

Ovakva metodologija odvaja teorijsku tvrdnju o mogućoj koristi tehnike od empirijskog dokaza na konkretnom skupu. Pобољшanje se može pripisati tehnici samo kada je poređenje kontrolisano i kada test skup nije učestvovao u njenom izboru ili učenju.

7. Praktična demonstracija na skupu oglasa

Praktični deo realizovan je u notebook-u `detect-fake-jobs.ipynb` i koristi `“fake_real_job_postings.csv”` sa 3000 oglasa i 25 kolona. Klase su potpuno balansirane: 1500 oglasa pripada klasi real, a 1500 klasi fake. Tekstualni ulaz formira se spajanjem naslova, opisa posla, zahteva, benefita i profila kompanije. Strukturirane kolone koriste se prvenstveno za audit, dok se klasifikacija zasniva na tekstu.

Početni pregled skupa prikazan je na slici 1:

job_id	job_title	job_description	requirements	benefits	company_name	company_profile	industry	employment_type	location	...	company_website	has_logo	num_open_positions	job_function	telecommuting	fraud_reason	text_length	is_fake	full_text	label
0	1	Data Analyst	Successful candidates communicate clearly with...	THE WORK REQUIRES ATTENTION TO DETAIL, CLEAR H...	Brightpath Solutions	Bonus eligibility depends on team results, del...	Software	Part-time	Budapest, Hungary	...	https://www.brightpathsolutions.eu	1	3	Analysis	0	NaN	1634	0	Data Analyst Successful candidates communicate...	real
1	2	Content Strategist	The work requires attention to detail, clear h...	Candidates should be comfortable learning inte...	OakLine Holdings	Flexible working hours with agreed core collab...	Logistics	Internship	Remote	...	https://www.oaklineholdings.co	1	1	Design	1	NaN	1558	0	Content Strategist The work requires attention...	real
2	3	Data Analyst	Successful candidates communicate clearly with...	Candidates should be comfortable learning inte...	SilverFern Holdings	MANAGER SUPPORT DURING ONBOARDING AND ACCESS T...	Human Resources	Part-time	Novi Sad, Serbia	...	https://www.silverfernholdings.eu	1	2	Analysis	0	NaN	1679	0	Data Analyst Successful candidates communicate...	real
3	4	Software Engineer	We are looking for someone who can balance day...	Our team works in short planning cycles and us...	OakLine Collective	Bonus eligibility depends on team results, del...	Education	Full-time	Berlin, Germany	...	https://www.oaklinecollective.eu	1	3	Development	0	NaN	1529	0	Software Engineer We are looking for someone w...	real
4	5	Data Analyst	Candidates should be comfortable learning inte...	You will partner with cross-functional team che...	BlueCedar Solutions	A mix of independent work and regular team che...	Education	Full-time	Budapest, Hungary	...	https://www.bluecedarsolutions.rs	1	1	Analysis	0	NaN	1904	1	Data Analyst Candidates should be comfortable ...	fake


5 rows x 27 columns

Slika 1: Inicijalnih 5 redova skupa podataka

Po klasi se mere broj karaktera, reči i rečenica, prosečna dužina reči i leksička raznovrsnost. Fake oglasi su u proseku duži: imaju oko 1960 karaktera, 270 reči i 17,7 rečenica, dok real oglasi imaju oko 1577 karaktera, 216 reči i 14,6 rečenica. Leksička raznovrsnost je nešto niža kod fake klase, 0,636 prema 0,662 kod real klase.

Ove razlike predstavljaju pomoćne signale, ali veliko preklapanje raspodela pokazuje da nijedna mera sama nije dovoljna za pouzdanu klasifikaciju.

Raspodele dužine dokumenta i leksička raznovrsnos prikazane su na slici 2:



Slika 2: Raspodela dužine dokumenta i leksička raznovrsnost

Analiza šuma obuhvata HTML oznake, URL i email obrasce, emoji simbole, spam fraze, ponovljenu interpunkciju, velika slova, ne-ASCII karaktere, tipografske i OCR-like zamene. Regex indikatori predstavljaju proxy mere: njihova svrha je da označe sumnjive obrasce, a ne da utvrde svaku pravopisnu ili OCR grešku sa lingvističkom sigurnošću.

Veličina rečnika iznosi 1174 tokena u fake klasi i 1155 u real klasi. Posmatrano nad svim dokumentima, sirovi tekst ima 747.050 tokena i rečnik od 2659 različitih whitespace oblika. Posle normalizacije rečnik opada na 483, posle uklanjanja stop-reči na 412, posle Porter stemminga na 347, a posle WordNet lematizacije na 394. Ovaj rezultat pokazuje koliko površinske varijacije, interpunkcija i oblici reči utiču na dimenzionalnost.

Tokenizacija se analizira na tri nivoa. Word tokenizacija koristi regularni izraz, sentence tokenizacija deli dokument na rečenice, a subword deo obuhvata karakterne n-grame i primer pretrained DistilBERT tokenizer-a. Karakterski n-grami pokazuju kako se reč može predstaviti preko svojih delova, dok pretrained tokenizer pokazuje kako savremeni modeli dele retke ili nepoznate reči na manje jedinice.

Primer razlaganja pravilnih, tipografski izmenjenih i nepoznatih reči pomoću character n-grama i DistilBERT tokenizer-a prikazana je na slici 3:

	word	word_tokens	char_4grams	distilbert_subwords
0	communication	[communication]	[comm, ommu, mmun, muni, unic, nica, icat, cati]	[communication]
1	communicat1on	[communicat1on]	[comm, ommu, mmun, muni, unic, nica, icat, cat1]	[com, ##mun, ##ica, ##t, ##1, ##on]
2	applicants	[applicants]	[appl, ppli, plic, lica, ican, cant, ants]	[applicants]
3	unseenword	[unseenword]	[unse, nsee, seen, eenw, enwo, nwor, word]	[unseen, ##word]

Slika 3: Subword tokenizacija

Normalizacija uklanja HTML, URL, email, brojeve, interpunkciju i emoji, primenjuje NFKC Unicode normalizaciju i casefold. Stop-reči se uklanjaju pomoću engleskog skupa iz scikit-learn biblioteke. PorterStemmer obezbeđuje agresivno morfološko sažimanje, dok NLTK

WordNetLemmatizer svodi reči na osnovni oblik na način koji je lakši za tumačenje, ali bez POS taggera ne može uvek pravilno da obradi sve gramatičke oblike.

Isti oglas prikazan je kroz pet verzija teksta: sirovu, normalizovanu, verziju bez stop reči, stemovanu i lematizovanu.

Promena ukupnog broja tokena, veličine rečnika i prosečne dužine dokumenta nakon svake faze predobrade prikazana je na slici 4:

	text_variant	total_tokens	vocabulary_size	avg_tokens_per_doc
0	raw_text	747050	2659	249.02
1	normalized_text	733301	483	244.43
2	no_stopwords_text	487747	412	162.58
3	stemmed_text	487747	347	162.58
4	lemmatized_text	487747	394	162.58

Slika 4: Statistika nakon svake faze predobrade

Data augmentation se primenjuje samo na trening podatke. Manji broj domenskih reči zamenjuje se sinonimima, a mali procenat tokena se uklanja. Pored toga, formira se kontrolisano zašumljen test tekst sa HTML oznakama, spam frazom i manjim brojem OCR/typo zamena. Ovaj test ne predstavlja prirodnu distribuciju svih mogućih grešaka, već kontrolisan eksperiment robusnosti.

8. Eksperimentalna postavka i baseline

Osnovna evaluacija koristi stratifikovanu podelu 80:20, odnosno 2400 trening i 600 test dokumenata. Test skup sadrži po 300 primera obe klase. Klasični eksperimenti obuhvataju Bag of Words, word TF-IDF, character TF-IDF, TF-IDF sa dodatnim metrikama kvaliteta i TF-IDF sa LSA redukcijom. Porede se sirovi, normalizovani, no-stopwords, stemmed i lemmatized tekst. Klasifikatori su LogisticRegression, MultinomialNB i LinearSVC.

Primarni baseline je Bag of Words nad sirovim tekstom sa logističkom regresijom. On ostvaruje F1 od 0,7739 i predstavlja referentnu vrednost za procenu tehnika predobrade i naprednijih reprezentacija. Normalizovani Bag of Words ostvaruje F1 0,7744, pa sama osnovna normalizacija u ovoj reprezentaciji donosi samo mali pomak. Svi ostali holdout rezultati porede se sa istom test podelom i istom pozitivnom klasom.

Stabilnost glavnih konfiguracija proverava se stratifikovanom petostrukom unakrsnom validacijom. Evaluacija koristi accuracy, precision, recall i F1. Za antifraud primenu recall fake klase ima posebnu važnost jer false negative predstavlja lažan oglas koji sistem nije zaustavio. Precision je važan zbog troška ručne provere legitimnih oglasa označenih kao sumnjivi.

Napredni dodatak koristi DistilBERT kao feature extractor. Pretrained model pretvara spojeni tekst oglasa u guste reprezentacije, a zatim se nad njima trenira LogisticRegression. Ova varijanta zadržava vrednost pretrained reprezentacija, ali izbegava složenost punog fine-tuning treninga.

Pregled svih klasičnih konfiguracija, korišćenih tekstualnih varijanti, reprezentacija i holdout metrika prikazana je na slici 5:

	experiment	text_variant	representation	model	augmented_train	quality_features	accuracy	precision	recall	f1
0	Subword char ngrams + LogisticRegression	normalized_text	Character n-gram TF-IDF	LogisticRegression	False	False	0.823333	0.854015	0.780000	0.815331
1	Subword char ngrams + LinearSVC	normalized_text	Character n-gram TF-IDF	LinearSVC	False	False	0.821667	0.848375	0.783333	0.814558
2	TF-IDF raw + LogisticRegression	raw_text	TF-IDF word ngrams	LogisticRegression	False	False	0.820000	0.842857	0.786667	0.813793
3	TF-IDF stemmed + LogisticRegression	stemmed_text	TF-IDF word ngrams	LogisticRegression	False	False	0.820000	0.842857	0.786667	0.813793
4	Dense LSA baseline + LogisticRegression	normalized_text	Dense LSA baseline	LogisticRegression	False	False	0.820000	0.842857	0.786667	0.813793
5	TF-IDF stemmed + MultinomialNB	stemmed_text	TF-IDF word ngrams	MultinomialNB	False	False	0.823333	0.864662	0.766667	0.812721
6	Augmented TF-IDF normalized + LogisticRegression	normalized_text	TF-IDF with train augmentation	LogisticRegression	True	False	0.813333	0.819728	0.803333	0.811448
7	TF-IDF normalized + LogisticRegression	normalized_text	TF-IDF word ngrams	LogisticRegression	False	False	0.816667	0.836879	0.786667	0.810997
8	TF-IDF lemmatized + LogisticRegression	lemmatized_text	TF-IDF word ngrams	LogisticRegression	False	False	0.816667	0.836879	0.786667	0.810997
9	TF-IDF stemmed + quality features	stemmed_text	TF-IDF + quality metrics	LogisticRegression	False	True	0.811667	0.816949	0.803333	0.810084
10	TF-IDF normalized + LinearSVC	normalized_text	TF-IDF word ngrams	LinearSVC	False	False	0.800000	0.790323	0.816667	0.803279
11	BoW normalized + LogisticRegression	normalized_text	Bag of Words	LogisticRegression	False	False	0.765000	0.744615	0.806667	0.774400
12	BoW raw + LogisticRegression	raw_text	Bag of Words	LogisticRegression	False	False	0.763333	0.740854	0.810000	0.773885

Slika 5: Pregled konfiguracija, tekstualnih varijanti, reprezentacija i holdout metrika

9. Rezultati i diskusija

9.1 Bag of Words i TF-IDF

Najbolji holdout rezultat među klasičnim konfiguracijama ostvaruje character n-gram TF-IDF sa logističkom regresijom: accuracy 0,8233, precision 0,8540, recall 0,7800 i F1 0,8153. Word TF-IDF nad sirovim i stemmed tekstom ostvaruje F1 0,8138, dok normalizovana i lemmatized varijanta imaju F1 oko 0,811. LinearSVC nad normalizovanim TF-IDF tekstom ostvaruje F1 0,8033, dok BoW sa logističkom regresijom zaostaje sa F1 vrednostima od približno 0,774.

U odnosu na sirovi Bag of Words baseline od 0,7739, najbolji character TF-IDF povećava F1 za 0,0414. Sirovi word TF-IDF povećava F1 za 0,0399, što pokazuje da najveći dobitak ne potiče samo od čišćenja teksta, već od informativnijeg načina ponderisanja i predstavljanja tokena. Normalizovani Bag of Words daje samo 0,0005 više od baseline-a, pa efekat normalizacije zavisi od reprezentacije sa kojom se kombinuje.

Petostruka unakrsna validacija daje još stabilniju sliku. Normalizovani word TF-IDF sa logističkom regresijom ima prosečni F1 0,8198 uz standardnu devijaciju 0,0162. Stemmed i raw TF-IDF varijante nalaze se odmah iza, sa F1 vrednostima 0,8187 i 0,8186. Character TF-IDF sa LinearSVC ostvaruje prosečni F1 0,8176, dok character TF-IDF sa logističkom regresijom ima F1 0,8157. Razlike su male, pa nije opravdano tvrditi da jedna predobrada univerzalno dominira. Glavni nalaz je da TF-IDF predstavlja stabilno jaku reprezentaciju za ovaj skup.

Dodavanje metrika kvaliteta TF-IDF reprezentaciji ne donosi poboljšanje. Augmentovani TF-IDF ima F1 0,8114, što je blizu osnovnim varijantama, ali bez jasne prednosti. Jednostavna sinonimska zamena i uklanjanje tokena zato se ne mogu preporučiti kao automatski koristan postupak.

Tabela unakrsne validacije sa prosečnim metrikama i standardnim devijacijama prikazana je na slici 6:

	experiment	accuracy_mean	accuracy_std	precision_mean	recall_mean	f1_mean	f1_std
0	TF-IDF normalized + LogisticRegression	0.8343	0.0128	0.8979	0.7547	0.8198	0.0162
1	TF-IDF stemmed + LogisticRegression	0.8337	0.0127	0.8990	0.7520	0.8187	0.0157
2	TF-IDF raw + LogisticRegression	0.8333	0.0128	0.8971	0.7533	0.8186	0.0162
3	Subword char ngrams + LinearSVC	0.8330	0.0110	0.9002	0.7493	0.8176	0.0141
4	Dense LSA baseline + LogisticRegression	0.8327	0.0116	0.9001	0.7487	0.8172	0.0144
5	TF-IDF normalized + LinearSVC	0.8240	0.0128	0.8532	0.7833	0.8162	0.0166
6	Subword char ngrams + LogisticRegression	0.8317	0.0110	0.9005	0.7460	0.8157	0.0140
7	BoW normalized + LogisticRegression	0.7853	0.0182	0.7944	0.7700	0.7817	0.0214

Slika 6: Unakrsna validacija

9.2 Word2Vec i FastText rezultati

Word2Vec i FastText eksperimenti predstavljaju dodatni pogled na problem reprezentacije teksta. Za razliku od TF-IDF pristupa, gde se dokument opisuje učestalošću tokena i njihovom informativnošću, embedding pristup prvo uči vektore reči iz trening korpusa. Zatim se svaki oglas predstavlja prosekom vektora reči koje sadrži.

Na test skupu Word2Vec + prosečni vektori + LogisticRegression ostvaruje accuracy 0,8250, precision 0,8598, recall 0,7767 i F1 0,8161. FastText + prosečni vektori + LogisticRegression ostvaruje accuracy 0,8200, precision 0,8529, recall 0,7733 i F1 0,8112. Rezultati su vrlo blizu najboljim TF-IDF modelima, što pokazuje da embedding pristup ima praktičnu vrednost iako je korpus relativno mali.

U odnosu na Bag of Words baseline, Word2Vec povećava F1 za 0,0422, a FastText za 0,0373. U ovom skupu Word2Vec je blago bolji, pa teorijska prednost FastText-a kod retkih i izmenjenih reči nije automatski dovela do bolje ukupne klasifikacije. Rezultat zavisi od korpusa, parametara i načina agregiranja vektora dokumenta.

Važno je naglasiti da se u ovom radu koristi jednostavno prosečavanje vektora reči. Takav pristup je razumljiv i brz, ali gubi redosled reči i deo lokalnog konteksta. Zbog toga se rezultati ne tumače kao maksimalan domet Word2Vec i FastText modela, već kao praktično poređenje jedne jasne embedding strategije sa TF-IDF reprezentacijama.

9.3 DistilBERT kao feature extractor

DistilBERT dodatak koristi pretrained model za dobijanje vektorskih reprezentacija teksta. Nad tim reprezentacijama trenira se LogisticRegression, što omogućava da se uporedi pretrained jezička reprezentacija sa klasičnim TF-IDF pristupom bez dodatnog fine-tuning treninga.

Na test skupu DistilBERT embeddings + LogisticRegression ostvaruje accuracy 0,8083, precision 0,7900, recall 0,8400 i F1 0,8142. Najbolji klasični model, Character n-gram TF-IDF sa logističkom regresijom, ostvaruje F1 0,8153. Razlika je mala, ali je metodološki važna: pokazuje da je dobro postavljen klasični model veoma konkurentan pretrained reprezentacijama na ovom skupu.

U odnosu na Bag of Words baseline, DistilBERT povećava F1 za 0,0403. Ipak, razlika između DistilBERT-a, Word2Vec-a i character TF-IDF-a manja je od dve hiljaditinke. Zbog toga izbor između njih treba zasnivati i na brzini, resursima, interpretabilnosti i ponašanju na spoljašnjem skupu, a ne samo na jednom holdout rezultatu.

Ovaj rezultat ne umanjuje vrednost Transformer-a. On pokazuje da izbor modela zavisi od odnosa performansi, brzine, interpretabilnosti i resursa. Za ovaj dataset character n-gram TF-IDF daje odličan odnos jednostavnosti i rezultata, dok DistilBERT predstavlja koristan napredni dodatak i poređenje sa savremenim pretrained pristupom.

9.4 Robusnost na kontrolisani šum

Word TF-IDF na čistom testu ostvaruje F1 0,8138, a na zašumljenom 0,8103, što predstavlja pad od 0,0034. Character TF-IDF pada sa 0,8168 na 0,8153, odnosno samo 0,0014. Manji pad karakterskog modela podržava teorijsku pretpostavku da subword reprezentacije bolje podnose lokalne promene unutar reči.


Padovi su mali zato što dodat šum zahvata ograničen deo teksta, dok su dokumenti relativno dugi. Rezultat zato ne dokazuje potpunu otpornost na šum, već pokazuje relativnu razliku dva modela u kontrolisanim uslovima. Za jaču tvrdnju bili bi potrebni realni OCR dokumenti, prirodne tipografske greške i više nivoa intenziteta šuma.

9.5 Analiza grešaka i interpretabilnost

Najbolji klasični model pravi 66 false negative i 40 false positive grešaka na 600 test primera. False negative slučajevi su kritičniji jer lažan oglas ostaje neprepoznat. False positive slučajevi stvaraju trošak dodatne moderatorske provere i rizik nepravednog blokiranja legitimnog sadržaja.

Koeficijenti interpretabilnog TF-IDF modela pokazuju tokene i n-grame koji najviše doprinose klasama. Takav pregled je koristan za otkrivanje shortcut signala. Ako se model oslanja na slučajne fraze, šablone generisanja ili informacije specifične za izvor podataka, visoka metrika ne mora značiti dobru generalizaciju.

Konfuzionna matrica najboljeg klasičnog modela prikazana je na slici 7:



Slika 7: Konfuzionna matrica Subword char ngrams + LogisticRegression

10. Uslovi primene, prednosti i ograničenja

Klasični TF-IDF pristup je pogodan kada postoji nekoliko hiljada označenih dokumenata, kada su leksičke razlike važne, kada je potrebna brza obuka i kada je interpretabilnost prioritet.

Njegove prednosti su jednostavnost, reproduktivnost i mala računarska cena. Ograničenja su slabo modelovanje dugog konteksta i zavisnost od tekstualnog preklapanja.

Character TF-IDF reprezentacija ima prednost kada su tipografske greške, morfološke varijacije i nepoznate reči česte. Njena mana je slabija neposredna interpretabilnost i mogućnost da karakterne sekvence uhvate površinske obrasce koji nisu semantički relevantni.

Pretrained DistilBERT je pogodan kada kontekst i formulacija imaju značaj i kada postoje resursi za računanje embeddings reprezentacija. Njegovi nedostaci su veća računarska cena, ograničenje dužine sekvence i slabija neposredna interpretabilnost.

Glavno ograničenje cele analize je jedan lokalni skup podataka. Klase su balansirane i tekstovi imaju ograničen rečnik, pa rezultati ne garantuju jednako ponašanje na oglasima drugih platformi, jezika ili vremenskih perioda.

10.1 Kvalitet oznaka i definicija ciljne klase

Kvalitet teksta nije jedina dimenzija koja određuje uspešnost nadgledanog modela. Podjednako je važno kako su formirane oznake real i fake. Ako dva anotatora ne koriste isti kriterijum, model dobija kontradiktoran signal koji se ne može ukloniti normalizacijom ili boljim tokenizerom.

U domenu oglasa za posao granica između nekvalitetnog i lažnog oglasa nije uvek jednostavna. Oglas može biti kratak, neprofesionalan ili pun grešaka, a da ipak predstavlja stvarnu ponudu. Obrnuto, dobro napisana prevara može sadržati detaljan opis posla i uverljiv profil kompanije. Zbog toga kriterijum klase fake treba da se zasniva na dokazivoj obmani, lažnom identitetu, pokušaju izvlačenja novca ili podataka, a ne samo na stilskim osobinama.

Za pouzdaniji skup preporučuje se anotacija najmanje dva nezavisna procenjivača, računanje mere slaganja i ručna revizija spornih primera. Korisno je čuvati i razlog označavanja: sumnjiv kontakt, zahtev za uplatu, nepostojeća kompanija, kopiran sadržaj ili drugi indikator. Takve pomoćne oznake omogućavaju detaljniju analizu grešaka i sprečavaju da binarna etiketa sakrije različite vrste prevare.

10.2 Dužina dokumenta i problem skraćivanja

Dužina oglasa ima dvostruku ulogu. Ona je metrika kvaliteta i potencijalna prediktivna osobina, ali istovremeno predstavlja tehničko ograničenje za Transformer modele. Klasični TF-IDF može obraditi ceo dokument, dok DistilBERT u praktičnom eksperimentu koristi najviše 192 tokena.

Skraćivanje čuva početak oglasa, ali može ukloniti zahteve, benefite, kontakt informacije ili profil kompanije koji se nalaze kasnije. Ako je signal prevare koncentrisan na kraju dokumenta, model ga neće videti. Ovaj problem je posebno izražen zato što spojeni tekst ima više semantički različitih polja.

Jedno rešenje je povećanje maksimalne dužine na 256 ili 512 tokena, uz veću potrošnju memorije i duže treniranje. Drugo rešenje je segmentacija: svako polje ili prozor dokumenta klasifikuje se odvojeno, a skorovi se agregiraju prosekom, maksimumom ili dodatnim modelom. Treće rešenje je hijerarhijska arhitektura koja prvo gradi reprezentaciju segmenata, a zatim reprezentaciju celog oglasa.

Uslov za izbor pristupa je raspoloživi hardver i analiza pozicije relevantnog signala. Ako su najinformativnije fraze uglavnom u naslovu i početku opisa, kratka sekvenca može biti dovoljna. Ako su važni detalji raspoređeni kroz ceo dokument, segmentacija je metodološki opravdanija.

10.3 Izbor tokenizacije kao kompromis

Word tokenizacija je jednostavna, interpretabilna i prirodno se povezuje sa BoW i TF-IDF reprezentacijama. Njena slabost je osetljivost na nepoznate reči i greške.

Karakterski n-grami rešavaju deo problema tako što reč predstavljaju velikim brojem preklapajućih fragmenata. Mala izmena menja samo deo fragmenata. Cena ove robusnosti je veći broj osobina i mogućnost da model nauči nizove koji nemaju samostalno jezičko značenje.

Pretrained DistilBERT zahteva sopstveni tokenizer. Taj tokenizer deli tekst na subword jedinice koje su usklađene sa pretrained težinama modela. Zamena tokenizatora lokalno naučenim pravilima prekinula bi vezu između token ID vrednosti i pretrained embeddinga. Zbog toga praktični deo koristi originalni tokenizer modela za DistilBERT prikaz, dok se subword robusnost u klasičnim modelima demonstrira pomoću character n-gram TF-IDF reprezentacije.

10.4 Normalizacija i rizik gubitka informacije

Normalizacija se često predstavlja kao nedvosmisleno korisna, ali svaka transformacija podrazumeva odluku o tome šta se smatra šumom. Case folding spaja TEAM, Team i team, ali uklanja signal neuobičajene upotrebe velikih slova. Uklanjanje interpunkcije smanjuje rečnik, ali može ukloniti višestruke uzvičnike koji predstavljaju spam indikator. Uklanjanje brojeva može ukloniti plate, godine iskustva, telefonske brojeve ili iznose koji su važni za procenu rizika.

Zato je u praktičnoj analizi sirova verzija zadržana kao zaseban eksperiment, a indikatori šuma izračunati su pre čišćenja. Ovakav dizajn omogućava da se informacija o stilu sačuva kao numerička metrika iako se iz glavnog teksta uklanjaju pojedini simboli.

Za klasične modele normalizacija često ima smisla jer direktno kontroliše veličinu rečnika. Za pretrained transformere treba biti umereniji. Model je pretreniran na prirodnom jeziku i njegov

tokenizer već zna kako da obradi interpunkciju, čestu kapitalizaciju i subword oblike. Preterano čišćenje može napraviti ulaz koji se razlikuje od jezika na kome je model stekao znanje.

10.5 Data augmentation i semantička validnost

Augmentation ima cilj da poveća raznovrsnost trening skupa bez promene oznake. Kod teksta je ovaj uslov teži nego kod mnogih transformacija slike. Zamena sinonima može promeniti ton ili domensko značenje, a nasumično uklanjanje reči može ukloniti negaciju ili ključni indikator prevare.

U ovom radu koriste se konzervativne transformacije: mali broj ručno izabranih domenskih sinonima i niska verovatnoća uklanjanja tokena. Augmentovani primeri se dodaju samo trening skupu. Time se sprečava da izvedena verzija test dokumenta postane deo učenja.

Rezultat bez poboljšanja pokazuje da veći broj primera nije sam po sebi dovoljan. Ako transformacije ne uvode korisnu varijabilnost, model dobija redundantne ili veštačke primere. Kvalitet augmentationa može se proveriti ručnim uzorkovanjem, merenjem semantičke sličnosti i posebnim ablation eksperimentima za svaku transformaciju.

Naprednije mogućnosti uključuju back translation, kontekstualnu zamenu reči i generativno parafraziranje. One mogu proizvesti prirodni tekst, ali uvode rizik promene oznake i dodatne računarske troškove.

10.6 Evaluacija, izbor modela i statistička nesigurnost

Kada se poredi veliki broj konfiguracija na istom test skupu, postoji rizik da se test skup posredno koristi za izbor modela. Najbolja konfiguracija može biti delimično posledica slučajne pogodnosti konkretne podele. Zato se glavni zaključak zasniva na unakrsnoj validaciji, dok holdout služi za konfuzionu matricu i kvalitativnu analizu grešaka.

Standardna devijacija F1 mere od oko 0,014 do 0,016 kod najboljih modela pokazuje da razlike manje od nekoliko hiljaditih nisu dovoljne za jaku tvrdnju o nadmoći. Normalizovani, lemmatized, stemmed i sirovi TF-IDF praktično su izjednačeni u granicama varijabilnosti podele.

Za još strožu procenu mogla bi se koristiti nested cross-validation, gde se unutrašnji foldovi koriste za izbor konfiguracije, a spoljašnji za nepristrasnu procenu. Bootstrap intervali poverenja ili testovi uparenih predikcija dodatno bi pokazali da li je razlika između modela statistički uverljiva.

Kod naprednog DistilBERT dodatka važno je da se pretrained reprezentacije računaju odvojeno za trening i test deo, a da se klasifikator trenira samo nad trening reprezentacijama. Ako bi se kasnije radio puni fine-tuning, tada bi bilo potrebno uvesti poseban validation skup za izbor epohe, praga i ostalih hiperparametara.

10.7 Promena domena i praćenje modela

Jezik oglasa i strategije prevaranata menjaju se vremenom. Model treniran na jednom periodu može oslabiti kada se pojave novi poslovi, platforme, skraćenice ili obrasci socijalnog inženjeringa. Ova pojava predstavlja data drift ili concept drift, zavisno od toga da li se menja raspodela ulaza ili veza između teksta i oznake.

Praćenje produkcionog sistema treba da uključi raspodelu dužine dokumenata, udeo nepoznatih tokena, promenu veličine rečnika, učestalost HTML-a, emoji i kontakt fraza, kao i raspodelu modelskih skorova. Nagla promena ne mora odmah značiti prevaru, ali zahteva pregled uzorka novih dokumenata.

Pored automatskih metrika potreban je tok povratne informacije moderatora. Potvrđeni false positive i false negative primeri predstavljaju najvrednije podatke za sledeću iteraciju modela. Aktivno učenje može prioritizovati oglase oko granice odluke ili primere kod kojih se TF-IDF i DistilBERT ne slažu.

Ponovno treniranje treba vezati za merljive indikatore, a ne samo za fiksni kalendar. Ako se performanse na novom ručno označenom uzorku pogoršaju ili se promeni struktura ulaza, opravdano je ažurirati podatke, prag ili model.

10.8 Operativna i etička primena

Automatska klasifikacija treba da bude deo sistema za podršku odluci. Model može dodeliti skor rizika, dok moderator donosi konačnu odluku kod oglasa iznad određenog praga. Za vrlo visok rizik moguće je privremeno zadržavanje oglasa, ali uz mogućnost žalbe i ljudske revizije.

Objašnjivost je važna za moderatore i poslodavce. Kod TF-IDF modela mogu se prikazati najuticajniji n-grami. Kod DistilBERT modela potrebni su dodatni postupci, ali objašnjenje ne sme biti predstavljeno kao dokaz uzročnosti. Najsigurnije je kombinovati modelsku procenu sa proverljivim pravilima, kao što su sumnjiv domen, zahtev za uplatu ili neusklađen identitet kompanije.

Podaci oglasa mogu sadržati lične informacije. Njihovo čuvanje, anotiranje i obrada moraju biti ograničeni na neophodnu svrhu, uz kontrolu pristupa i rokove zadržavanja. Model ne treba da koristi zaštićene ili osetljive osobine za diskriminatorno rangiranje poslodavaca i kandidata.

Konačno, kvalitet sistema ne meri se samo F1 merom. Potrebno je pratiti broj sprečenih prevara, vreme moderatorske obrade, procenat opravdanih žalbi i posledice grešaka. Tek kombinacija modelskih, operativnih i etičkih kriterijuma daje realnu procenu vrednosti sistema.

11. Zaključak

Analiza pokazuje da kvalitet tekstualnih podataka obuhvata mnogo više od uklanjanja praznih vrednosti. Dužina dokumenta, veličina rečnika, leksička raznovrsnost, HTML, emoji, spam, tipografske i OCR-like greške menjaju reprezentaciju koju model dobija. Tokenizacija, Unicode normalizacija, uklanjanje stop-reči, stemming, WordNet lematizacija i data augmentation zato moraju biti posmatrani zajedno sa vrstom reprezentacije i modela.

Klasični TF-IDF modeli predstavljaju najstabilniju i najekonomičniju polaznu tačku. Normalizovani word TF-IDF ostvaruje prosečni cross-validation F1 od 0,8198, dok character TF-IDF na holdout skupu ostvaruje F1 0,8153 i pokazuje manji pad pri kontrolisanom šumu. Razlike među TF-IDF varijantama su male, pa agresivnija predobrada u ovom skupu nije donela jasnu korist.

Word2Vec sa prosečnim vektorima ostvaruje F1 0,8161, FastText F1 0,8112, a DistilBERT kao feature extractor F1 0,8142. Ovi rezultati su vrlo blizu najboljem klasičnom modelu. Zaključak je da različite reprezentacije mogu dati sličan nivo performansi, ali uz različit odnos jednostavnosti, brzine i interpretabilnosti.

Ne postoji univerzalno najbolja predobrada niti model. Izbor zavisi od kvaliteta skupa, količine označenih podataka, računarskih resursa, interpretabilnosti i troška false positive i false negative grešaka. Za praktičnu primenu najrazumniji je hibridni sistem: brz i interpretabilan TF-IDF model kao osnovni signal, pretrained transformer za semantički teže slučajeve i ljudska revizija za oglase visokog rizika.

12. Literatura

[1] D. Jurafsky and J. H. Martin, Speech and Language Processing, 3rd ed. draft, 2024.
<https://web.stanford.edu/~jurafsky/slp3/>

[2] C. D. Manning, P. Raghavan and H. Schütze, Introduction to Information Retrieval, Cambridge University Press, 2008. <https://nlp.stanford.edu/IR-book/>

[3] scikit-learn documentation, Text feature extraction. https://scikit-learn.org/stable/modules/feature_extraction.html#text-feature-extraction

[4] scikit-learn documentation, Metrics and scoring: quantifying the quality of predictions. https://scikit-learn.org/stable/modules/model_evaluation.html

[5] NLTK documentation, WordNetLemmatizer.
<https://www.nltk.org/api/nltk.stem.WordNetLemmatizer.html>

[6] Gensim documentation, Word2Vec embeddings.
<https://radimrehurek.com/gensim/models/word2vec.html>

[7] fastText documentation, Word representations. <https://fasttext.cc/docs/en/unsupervised-tutorial.html>

[8] Hugging Face Transformers documentation, DistilBERT.
https://huggingface.co/docs/transformers/en/model_doc/distilbert

[9] Keras documentation, LSTM layer. https://keras.io/api/layers/recurrent_layers/lstm/